

BattAIHealth: AI for Battery Health Monitoring

Pedro André Silva Ferreira

Engenharia Eletrotécnica e de Computadores
Ramo de Eletrónica e Computadores

21 Julho 2025

Conteúdos

1. Introdução
2. Fundamentos Teóricos
3. Estado da Arte
4. Desenvolvimento
5. Experiências e Resultados
6. Discussão e Análise

Introdução

Motivação

Contexto

- Veículos elétricos e comboios eletrificados dependem de monitorização precisa da saúde das baterias
- Parâmetros críticos: Estado de carga (SOC), Estado de saúde (SOH) e Vida útil restante (RUL)
- Processos químicos complexos que mudam com temperatura, padrões de uso e envelhecimento

Limitações dos Métodos Atuais

- Métodos tradicionais (coulomb counting, filtros de Kalman) têm limitações
- Funcionam bem em ambientes controlados, mas falham em condições reais
- Acumulação de erros ao longo do tempo

Objetivos do Trabalho

Objetivo Principal

Desenvolver métodos baseados em IA para prever SOC, SOH e RUL simultaneamente e com precisão

Parâmetros a Estimar

- **Estado de Carga (SOC):** Energia remanescente na bateria
- **Estado de Saúde (SOH):** Capacidade atual vs. capacidade original
- **Vida Útil Remanescente (RUL):** Ciclos até degradação crítica

Contribuições

- Comparação entre abordagens baseadas em diferentes redes neurais
- Adaptação da arquitetura TimesNet para dados de baterias

Fundamentos Teóricos

Conceitos Fundamentais - Parâmetros das Baterias

Estado de Carga (SOC)

$$SOC = \frac{\text{Carga Remanescente}}{\text{Capacidade Máxima}} \times 100\%$$

- Estimativa aproximada devido à complexidade química
- Não-linearidade causada por degradação dos eletrodos

Estado de Saúde (SOH)

$$SOH = \frac{\text{Capacidade Máxima Atual}}{\text{Capacidade Máxima Original}} \times 100\%$$

- Fadiga progressiva dos materiais
- Diminuição da área superficial ativa

Visualização da Degradação




Figura: Capacidade




Figura: Estado de Saúde (SOH)





Figura: Estado de Carga (SOC)

Degradação e Envelhecimento das Baterias

Mecanismos de Degradação

- **Formação SEI:** Crescimento da interface sólido-eletrólito
- **Perda de Lítio:** Redução do lítio ativo disponível
- **Degradação estrutural:** Mudanças na estrutura dos eletrodos
- **Impedância:** Aumento da resistência interna



Fatores que Afetam a Degradação

Fatores que Afetam a Degradação

- Temperatura de operação
- Profundidade de descarga
- Taxa de carga/descarga
- Número de ciclos

Estado da Arte

Métodos Tradicionais

Modelos de Circuito Equivalente:

- Modelo de Thévenin
- Modelo PNGV
- Representam comportamento eletroquímico

Coulomb Counting:

- Integração da corrente
- Acumulação de erros
- Limitações de precisão

Filtros de Kalman:

- Filtro de Kalman Estendido (EKF)
- Estimativa de estado
- Fusão de sensores

Limitações

- Não-linearidade
- Variabilidade ambiental
- Envelhecimento não modelado

Métodos Baseados em IA

Redes Neurais Recorrentes

- RNNs básicas com memória limitada
- LSTMs para dependências temporais longas
- Melhor modelação da degradação da bateria

Arquiteturas Avançadas

- **Transformers:** Mecanismos de atenção para sequências longas
- **Mixture of Experts (MoE):** Especialização para diferentes padrões

Vantagens da IA


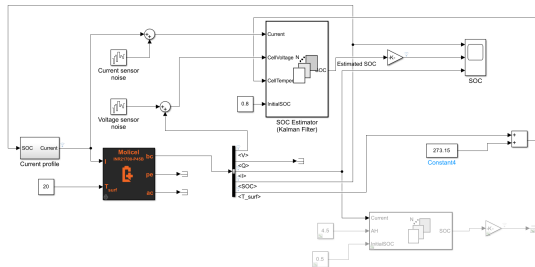
- Captura de padrões complexos e não-lineares
- Adaptação a diferentes condições
- Aprendizagem de relações ocultas

Desenvolvimento

Modelação MATLAB e Simulação

Implementação EKF em Simulink

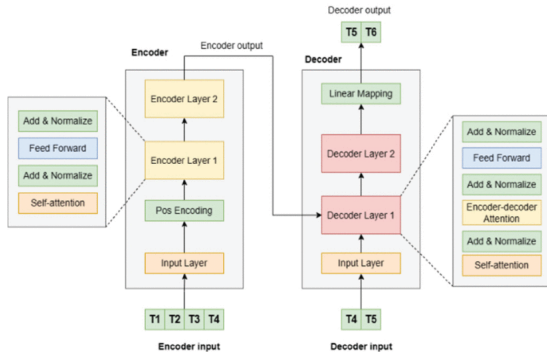
- Framework completo de simulação
- Estimativa de SOC utilizando filtro de Kalman estendido
- Integração com modelo Batemo INR21700-p45b



Arquiteturas Neurais Baseline

Transformer


- Mecanismos de auto-atenção (detetar quais são os padrões mais relevantes)
- Excelente para sequências longas
- Alta precisão mas computacionalmente intensivo



Arquiteturas Neurais Baseline: Mixture of Experts

Mixture of Experts

- Rede de roteamento com especialistas
- Eficiente – ativa apenas especialistas relevantes
- Adequado para multi-tarefas



Comparação de Desempenho: Dataset CALCE CS2

Tabela: Comparação de Desempenho na Previsão de RUL, Raiz do Erro Quadrático Médio

Modelo	RMSE
Transformer	0.0297
FCN MoE	0.0335

Visualização dos Resultados de Previsão de RUL

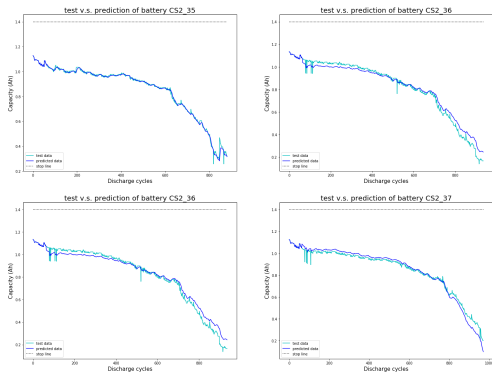


Figura: Resultados do Transformer


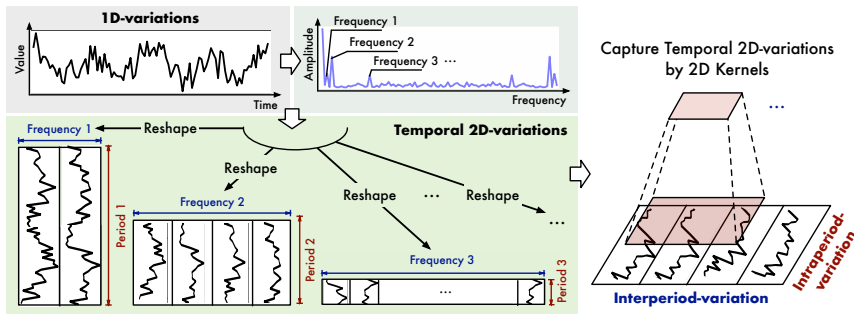


Figura: Resultados do MoE

Método Escolhido: TimesNet

Porquê TimesNet?

- **Especialização:** Concebido especificamente para análise de séries temporais
- **Multi-periodicidade:** Deteta múltiplos padrões temporais simultaneamente
- **Transformação 2D:** Converte dados 1D em tensors 2D para processamento com CNNs



Método Escolhido: TimesNet

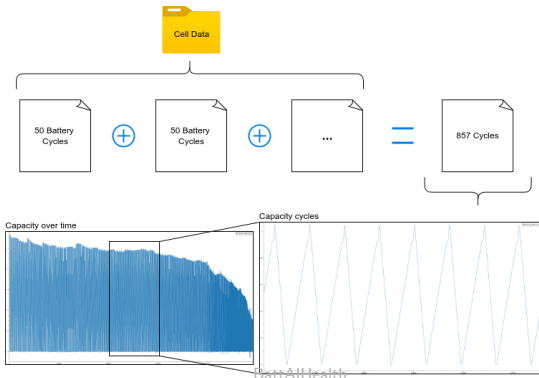
Vantagens para Dados de Bateria

- Captura padrões de curto prazo (ciclos de carga/descarga)
- Deteta tendências de longo prazo (degradação)
- Usa FFTs para facilitar a descoberta de periodicidades

Dataset CALCE CS2

Características do Dataset

- **880 ciclos** de operação por cada bateria Li-ion do dataset CALCE CS2
- Medições incluem tensão, corrente, tempo, temperatura, capacidade, etc.
- Dados organizados sistematicamente por múltiplos ciclos de carga/descarga



Metodologia de Pré-processamento

Metodologia de Pré-processamento

- Cálculo derivado de SOC, SOH e RUL com base nos dados de capacidade
- Segmentação em ciclos
- Divisão do dataset: 70% treino, 15% validação, 15% teste

Adaptação

- **Entradas:** Tensão, corrente, tempo.
- **Alvos:** SOC, SOH, RUL

Metodologia e Otimização de Hiperparâmetros

Ferramentas e Processo

- **Ferramentas:**
 - Optuna para otimização
 - Weights & Biases para monitorização
- **Processo:**
 - 50 tentativas, cada uma com 50 epochs
 - Objetivo: Minimizar o MSE na validação

Parâmetros Otimizados

- e_layers: N^o de camadas do encoder (1-3)
- d_layers: N^o de camadas do decoder (1-3)
- factor: Fator de expansão para a FFN (1-5)
- freq: Frequência para codificação temporal
- top_k: N^o de frequências dominantes (TimesNet)

Visualização da Otimização



Figura: Optuna Objective Plot

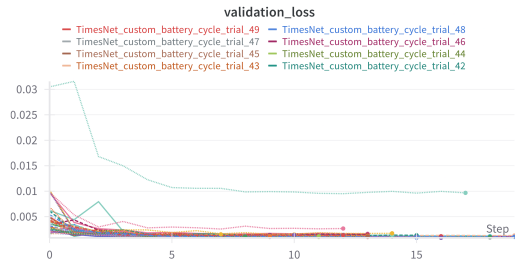


Figura: W&B Validation Loss

Experiências e Resultados

Configuração e Desempenho do Modelo

Configuração Final

- **43 Epochs** de treino
- Loss de validação final: **0,02939**
- Arquitetura com **37,5M parâmetros**
- Memória ocupada: 140 MB

Divisão dos Dados

- 120000 amostras para treino (70%)
- 4900 amostras para validação (15%)
- 4900 amostras para teste (15%)

Tabela: Métricas de Desempenho por Parâmetro

Parâmetro	RMSE	MAE
SOC	0,2251	0,0621
SOH	0,5282	0,2039
RUL	0,5311	0,2078



Análise de Resultados e Hierarquia de Desempenho

Desempenho

1. **SOC**: Melhor precisão (RMSE: 0,2251)
 - Correlação direta com medições elétricas
 - Padrões cíclicos bem definidos
2. **SOH**: Desempenho moderado (RMSE: 0,5282)
 - Degradação gradual mais complexa
3. **RUL**: Maior desafio (RMSE: 0,5311)
 - Previsão de tendências futuras




Figura: Valores reais vs preditos (SOC)

Tabela: Comparação de Abordagens (RMSE em RUL)

Modelo	RMSE
Transformer (tarefa única)	0,0297
MoE (tarefa única)	0,0335
TimesNet (multi-tarefa)	0,5311

Desafios da Abordagem Multi-tarefa

Principais Limitações

- **Temporais:** SOC (curto prazo) vs SOH/RUL (longo prazo)
- **Computacionais:** 37,5M parâmetros (140 MB)
- **Treino:** Gradientes em conflito entre tarefas
- **Implementação:** Inviável em sistemas embebidos

Impacto no Desempenho

- Neste caso o modelo especializado supera a abordagem unificada
- 18x pior no RMSE para RUL (0,0297 → 0,5311)

Conclusão

Soluções abrangentes nem sempre são ótimas para problemas específicos como monitorização de baterias.

Discussão e Análise

Limitações e Direções Futuras

Limitações do Estudo

- **Generalização limitada:** Dataset CALCE CS2
- **Gap laboratorial:** Condições controladas vs. reais
- **Diversidade química:** Li-ion específicas
- **Implementação:** Elevados requisitos computacionais

Direções Futuras

- **Ensemble methods:** CNNs para SOC, LSTMs para RUL
- **Transfer learning:** Reutilizar conhecimento entre tipos de baterias
- **Model compression:** Distilação, pruning e quantização

Lição Principal

Resolver SOC, SOH e RUL simultaneamente pode não ser ideal para desempenho superior individual.

Obrigado!

BattAIHealth

Battery Condition Estimation in Automotive and Railway Applications Using AI

Perguntas e Discussão

Pedro André Silva Ferreira Projeto Final - Engenharia Eletrotécnica e de Computadores Instituto
Politécnico de Leiria Julho 2025

Referências Principais

-  Haixu Wu, Tengge Hu, Yong Liu, Hang Zhou, Jianmin Wang, Mingsheng Long. *TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis*. arXiv:2210.02186 [cs], 2023. doi: 10.48550/arXiv.2210.02186.
-  CALCE Battery Research Group. *Battery Data | Center for Advanced Life Cycle Engineering*. University of Maryland. <https://calce.umd.edu/battery-data>
-  Daoquan Chen, Weicong Hong, Xiuze Zhou. *Transformer Network for Remaining Useful Life Prediction of Lithium-Ion Batteries*. IEEE Access, vol. 10, pp. 19621–19628, 2022. doi: 10.1109/ACCESS.2022.3151975.
-  Takuya Akiba, Shotaro Sano, et al. *Optuna: A Next-generation Hyperparameter Optimization Framework*. KDD, 2019.
-  Noam Shazeer, Azalia Mirhoseini, et al. *Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer*. ICLR, 2017.